

Recuperación de Información: Evaluación Comparativa de Sistemas de Búsqueda

Autor: David Fernando Bolaños López (UO302313)

Asignatura: Repositorios de Información

Tabla de Contenido

Introducción.....	3
Ejercicio 1: Evaluación de una Única Consulta con BM25s	3
Ejercicio 2: Evaluación Automática del Buscador BM25s	6
Ejercicio 3: Evaluación de una Única Consulta con ChromaDB	8
Ejercicio 4: Evaluación Automática del Buscador ChromaDB	9
Ejercicio 5: Evaluación de una Única Consulta con Búsqueda Híbrida	10
Ejercicio 6: Evaluación Automática del Buscador Híbrido	11
Ejercicio 7: ChromaDB con Chunks Contextualizados	12
Ejercicio 8: Sistema RAG con Chunks Agrupados	14
Ejercicio 9: Evaluación de Sistemas RAG mediante LLMs	15
Análisis Comparativo General.....	19
Conclusiones	21
Referencias	22

Introducción

Este documento presenta un análisis integral y riguroso de tres enfoques diferentes para la recuperación de información biomédica, utilizando la colección de consultas NFcorpus y un corpus de artículos obtenidos de PubMed. La evaluación sistemática abarca desde casos individuales de consultas hasta métricas agregadas sobre el conjunto completo, permitiendo una comprensión exhaustiva del comportamiento de cada modelo en diversos escenarios.

Modelos Evaluados

- **BM25s:** Modelo de recuperación basado en coincidencias léxicas directas, que calcula la relevancia mediante análisis de términos exactos presentes en documentos y consultas
- **ChromaDB:** Sistema de recuperación semántica basado en embeddings vectoriales, que captura significado contextual más allá de coincidencias léxicas
- **Búsqueda Híbrida:** Combinación de ambos enfoques mediante Reciprocal Rank Fusion (RRF), fusionando inteligentemente las fortalezas de cada modelo

El análisis se estructura desde lo particular (evaluación de consultas individuales) hasta lo general (métricas agregadas), permitiendo identificar patrones de comportamiento específicos y emergentes a nivel global.

Ejercicio 1: Evaluación de una Única Consulta con BM25s

Consulta de Referencia: PLAIN-382

- **URL de Origen:** <http://nutritionfacts.org/questions/is-vanilla-sweetened-almond-milk-healthy/>
- **Título:** Is vanilla almond milk healthy?
- **Narrativa:** How about Almond Milk? Been drinking as replacement for cow milk, love the taste, etc. However, I do buy the Vanilla sweetened flavor...is that bad? Am I taking away from the good of it all?
- **Keywords:** almond milk vanilla sweetened health

Documentos Relevantes Conocidos

Según el archivo qrels.txt, los documentos relevantes para PLAIN-382 son:

Documento	Relevancia
MED-873	2

MED-874	2
MED-875	2
MED-4172	1
MED-4173	1

Table 1: Documentos relevantes para PLAIN-382 (Total: 5)

Resultados por Variante de Consulta

Variante por Título

Consultando únicamente "Is vanilla almond milk healthy?", BM25s devuelve los siguientes resultados en top-10:

Rango	ID	Score	Título	Relevancia
1	MED-204	6.4031	Milk stimulates growth of prostate cancer cells in culture	X
2	MED-875	6.3168	Inhibition of bacterial quorum sensing by vanilla extract	✓
3	MED-4297	5.5990	Effects of almond consumption on the reduction of LDL-cholesterol	X
4	MED-4249	4.9088	Crossover study of diets enriched with virgin olive oil, walnuts or almonds	X
5	MED-5073	4.7605	Polyphenols and antioxidant properties of almond skins	X
6-10	...	...	...	X

Table 2: Resultados de BM25s: Variante Título

Métricas Calculadas:

$$P@10 = \frac{1}{10} = 0.10$$

$$R@10 = \frac{1}{5} = 0.20$$

Variante por Keywords

Usando "almond milk vanilla sweetened health" como consulta, los resultados mejoran significativamente:

Métricas Calculadas:

$$P@10 = \frac{1}{10} = 0.10$$

$$R@10 = \frac{1}{5} = 0.20$$

Variante por Narrativa

La consulta narrativa completa produce resultados sustancialmente diferentes:

Métricas Calculadas:

$$P@10 = \frac{0}{10} = 0.00$$

$$R@10 = \frac{0}{5} = 0.00$$

Resumen de Resultados - Ejercicio 1

Variante	P@10	R@10
Título	0.10	0.20
Keywords	0.10	0.20
Narrativa	0.00	0.00

Table 3: Comparación de variantes de consulta en BM25s

Análisis de Resultados

Las variantes de título y keywords ofrecen un rendimiento idéntico ($P@10 = 0.10$, $R@10 = 0.20$), recuperando únicamente 1 de los 5 documentos relevantes en el top-10. Este resultado es coherente: ambas son consultas concisas centradas en términos informativos clave (almond milk, vanilla, sweetened, health), permitiendo que BM25 asigne pesos comparables.

Sin embargo, la exhaustividad de 0.20 implica que el sistema solo recupera el 20% de los documentos relevantes conocidos. Los cuatro documentos restantes permanecen fuera del top-10.

La variante narrativa presenta un fracaso completo ($P@10 = 0$, $R@10 = 0$). Este comportamiento se debe a que la narrativa introduce palabras con bajo poder discriminativo (love, taste, taken away, been drinking, replacement) que generan coincidencias superficiales con múltiples documentos irrelevantes. Estas palabras "de relleno" diluyen los términos realmente informativos, causando que BM25 recupere artículos sobre leche, nutrición y sustitutos lácteos sin priorizar correctamente los documentos verdaderamente relevantes.

Ejercicio 2: Evaluación Automática del Buscador BM25s

Metodología

Se evaluó BM25s sobre el conjunto completo de 354 consultas del corpus NFCorpus utilizando las métricas estándar de recuperación de información:

$$P@k = \frac{\text{Documentos relevantes recuperados en top-}k}{k}$$

$$R@k = \frac{\text{Documentos relevantes recuperados en top-}k}{\text{Total de documentos relevantes}}$$

$$F1@k = \frac{2 \cdot P@k \cdot R@k}{P@k + R@k}$$

Resultados Agregados

Métrica	Valor
Media P@100	0.0588
Media R@100	0.3606
Media F1@100	0.0879

Table 4: Métricas agregadas de BM25s sobre 354 consultas

Análisis Estadístico Detallado

Precisión P@100:

- Media: 0.0588 ± 0.0568 (Desviación estándar)
- Coefficiente de variación: 96.47%
- Rango: [0.0000, 0.3200]
- Cuartiles: Q1=0.0200, Mediana=0.0400, Q3=0.0900

El coeficiente de variación del 96.47% indica **alta variabilidad** en el rendimiento de BM25s entre consultas.

Exhaustividad R@100:

- Media: 0.3606 ± 0.3102
- Coefficiente de variación: 86.02%
- Rango: [0.0000, 1.0000]
- Cuartiles: Q1=0.1250, Mediana=0.2727, Q3=0.5000

F1-Score F1@100:

- Media: 0.0879 ± 0.0757
- Coeficiente de variación: 86.18%
- Rango: [0.0000, 0.4031]
- Cuartiles: $Q1=0.0298$, Mediana= 0.0635 , $Q3=0.1355$

Análisis de Patrones de Rendimiento

Se clasificaron las 354 consultas en tres grupos según su $F1@100$:

Rendimiento BAJO (128 consultas, 36.2%):

- $F1@100$ promedio: 0.0195 (± 0.0143)
- $P@100$ promedio: 0.0107
- $R@100$ promedio: 0.3287
- Características: Consultas genéricas o en lenguaje muy coloquial sin terminología técnica clara

Rendimiento MEDIO (109 consultas, 30.8%):

- $F1@100$ promedio: 0.0708 (± 0.0168)
- $P@100$ promedio: 0.0449
- $R@100$ promedio: 0.3382
- Características: Consultas con vocabulario mixto (coloquial + técnico)

Rendimiento ALTO (117 consultas, 33.0%):

- $F1@100$ promedio: 0.1786 (± 0.0569)
- $P@100$ promedio: 0.1245
- $R@100$ promedio: 0.4164
- Características: Consultas técnicas con terminología especializada coincidente con el corpus

Análisis de Consultas Extremas

Consultas con Mejor Rendimiento

PLAIN-2501: "Which Dietary Factors Affect Breast Cancer Most?"

Métrica	Valor
$P@100$	0.32
$R@100$	0.2936
$F1@100$	0.3062
Total relevantes	109

Table 5: Desempeño de BM25s en PLAIN-2501

El éxito se atribuye a: terminología técnica estándar en biomedicina, gran número de documentos relevantes (109), y coincidencias léxicas directas.

Ejercicio 3: Evaluación de una Única Consulta con ChromaDB

Configuración del Experimento

Se utilizó ChromaDB, un sistema de recuperación basado en embeddings vectoriales, con la misma consulta PLAIN-382 y variantes idénticas a las del Ejercicio 1.

Resultados por Variante

Variante por Título

ChromaDB con "Is vanilla almond milk healthy?" devuelve documentos relacionados con leche y salud, pero **ninguno coincide con los documentos marcados como relevantes en qrels.txt**.

Métricas:

- $P@10 = 0.00$
- $R@10 = 0.00$

Variante por Keywords

Métricas:

- $P@10 = 0.00$
- $R@10 = 0.00$

Variante por Narrativa

Métricas:

- $P@10 = 0.00$
- $R@10 = 0.00$

Resumen de Resultados - Ejercicio 3

Variante	P@10	R@10
Título	0.00	0.00
Keywords	0.00	0.00

Narrativa	0.00	0.00
-----------	------	------

Table 6: Resultados de ChromaDB para PLAIN-382

Análisis Detallado

Contrariamente a BM25s, que recuperaba al menos un documento relevante (MED-875) en el top-10 para las variantes de título y keywords, ChromaDB no encuentra ninguno de los cinco documentos marcados como relevantes en ninguna de las tres variantes.

El modelo semántico capta bien la idea general de "leche y salud", recuperando artículos sobre bebidas vegetales, bebidas lácteas, nutrición y factores de riesgo. Sin embargo, esta generalización semántica es demasiado amplia para distinguir los documentos específicos que qrels ha etiquetado como relevantes, que quedan diluidos entre artículos semánticamente parecidos pero no pertinentes.

Comparación BM25s vs ChromaDB para PLAIN-382:

- BM25s:** Recupera documentos por coincidencia léxica exacta (p. ej., MED-875 contiene "vanilla")
- ChromaDB:** Agrupa documentos semánticamente relacionados, pero sin la especificidad necesaria para esta consulta

Ejercicio 4: Evaluación Automática del Buscador ChromaDB

Resultados Agregados

Métrica	Valor
Media P@100	0.0611
Media R@100	0.3682
Media F1@100	0.0912

Table 7: Métricas agregadas de ChromaDB sobre 354 consultas

Comparación Global: BM25s vs ChromaDB

Métrica	BM25s	ChromaDB	Diferencia	Diferencia %
P@100	0.0588	0.0611	+0.0023	+3.89%
R@100	0.3606	0.3682	+0.0076	+2.11%
F1@100	0.0879	0.0913	+0.0034	+3.82%

Table 8: Comparación de rendimiento: BM25s vs ChromaDB (diferencias inapreciables)

Conclusión: Todas las diferencias son menores al 5%, clasificándose como **inapreciables** según los criterios estándar. A nivel agregado, ambos modelos tienen rendimiento equivalente.

Análisis de Consultas Extremas

PLAIN-2532: "Can Flax Seeds Help Prevent Breast Cancer?"

Modelo	P@100	R@100	F1@100
BM25s	0.19	0.33	0.24
ChromaDB	0.29	0.51	0.37

Table 9: PLAIN-2532: Ventaja clara de ChromaDB

ChromaDB supera claramente a BM25s, capturando sinónimos (flaxseed vs. flax seeds), paráfrasis (protective effect vs. help prevent) y conceptos equivalentes aunque léxicamente distintos.

PLAIN-3257: "Is Stevia Good For You?"

Modelo	P@100	R@100	F1@100
BM25s	0.02	0.10	0.0333
ChromaDB	0.12	0.60	0.2

Table 10: PLAIN-3257: Mejora espectacular (+500%) en ChromaDB

Mejora espectacular en ChromaDB: F1@100 aumenta +500%. La pregunta está completamente en lenguaje coloquial, mientras que los artículos científicos emplean "safety of stevia", "non-nutritive sweeteners", "health effects". ChromaDB asocia correctamente "good for you" con conceptos de seguridad.

Ejercicio 5: Evaluación de una Única Consulta con Búsqueda Híbrida

Metodología de Fusión

Se utilizó **Reciprocal Rank Fusion (RRF)** para combinar rankings de BM25s y ChromaDB:

$$\text{RRF}(d) = \sum_{\text{rank}_i(d)} \frac{1}{k + \text{rank}_i(d)}$$

donde $k=60$ (parámetro estándar).

Resultados por Variante

Variante	BM25s	ChromaDB	Híbrida
Título (P@10/R@10)	0.10/0.20	0.00/0.00	0.00/0.00
Keywords (P@10/R@10)	0.10/0.20	0.00/0.00	0.00/0.00
Narrativa (P@10/R@10)	0.00/0.00	0.00/0.00	0.00/0.00

Table 11: Comparación de variantes para búsqueda híbrida

Análisis del Comportamiento Híbrido

Para PLAIN-382, la búsqueda híbrida empeora respecto a BM25s (cuando este es mejor) porque:

1. RRF favorece documentos que aparecen en ambos rankings
2. ChromaDB devuelve documentos distintos a los de BM25s
3. Los pocos documentos "consensuados" entre ambos rankings son artículos genéricos sobre leche y salud
4. El único relevante que BM25s colocaba en top-10 se ve adelantado por estos documentos genéricos

Conclusión para PLAIN-382: La combinación RRF con criterios simétricos no logra explotar la ventaja de BM25s, resultando en degradación del rendimiento.

Ejercicio 6: Evaluación Automática del Buscador Híbrido

Resultados Agregados

Métrica	Valor
Media P@100	0.0595
Media R@100	0.3706
Media F1@100	0.0893

Table 12: Métricas agregadas del buscador híbrido

Comparación Global de los Tres Modelos

Modelo	P@100	R@100	F1@100
BM25s	0.0588	0.3636	0.0879

ChromaDB	0.0611	0.3668	0.0912
Híbrida	0.0595	0.3706	0.0893

Table 13: Comparación global: Los tres modelos de recuperación

Análisis de Diferencias

Comparación	P@100	R@100	F1@100	Conclusión
ChromaDB vs BM25s	+3.8%	+1.7%	+3.7%	Ligera ventaja semántica
Híbrida vs BM25s	+1.1%	+2.8%	+1.6%	Mejora marginal
Híbrida vs ChromaDB	-2.6%	+1.0%	-2.0%	Equilibrio aproximado

Table 14: Análisis de diferencias entre modelos

Interpretación: Todas las diferencias son menores al 5%, inapreciables estadísticamente a nivel agregado. Ningún modelo destaca sobre los otros en promedio. Lo relevante es el comportamiento consulta a consulta.

Análisis de Consultas Extremas

PLAIN-198: "Which Pets Improve Children's Health?"

Modelo	P@100	R@100	F1@100
BM25s	0.06	0.17	0.09
ChromaDB	0.04	0.11	0.06
Híbrida	0.07	0.19	0.1

Table 15: PLAIN-198: Híbrida supera a ambos modelos (+10%)

El híbrido supera a ambos modelos individuales con mejora sustancial (>10% en F1@100). Esto refleja complementariedad: BM25s captura coincidencias literales, ChromaDB entiende conceptos equivalentes, y RRF premia documentos bien posicionados en ambos rankings.

Ejercicio 7: ChromaDB con Chunks Contextualizados

Metodología

Se modificó el buscador ChromaDB para indexar chunks contextualizados, donde cada chunk se construye concatenando el título del artículo, el abstract y el fragmento correspondiente.

Esta contextualización proporciona información adicional a cada fragmento, permitiendo que el modelo de embeddings capture mejor la relevancia semántica de cada pasaje.

Adicionalmente, se implementó un sistema de deduplicación que elimina apariciones múltiples del mismo documento en los resultados, priorizando diversidad.

Resultados Agregados

Métrica	Baseline	Contextual	Diferencia	Evaluación
P@100	0.0612	0.0657	+7.50%	Sustancial
R@100	0.3682	0.3648	-0.92%	Inapreciable
F1@100	0.0913	0.0971	+6.33%	Sustancial

Table 16: ChromaDB con chunks contextualizados vs baseline

Análisis de Resultados Globales

El buscador contextualizado mejora la precisión en un 7.5%, incrementando de 0.0612 a 0.0657. Esto significa que, de los 100 documentos devueltos, aproximadamente 6-7 son relevantes frente a los 6 del baseline.

La exhaustividad disminuye marginalmente en 0.92%, pasando de 0.3682 a 0.3648. Esta reducción es prácticamente inapreciable y se debe a que el sistema de deduplicación elimina documentos repetidos.

El F1@100 mejora en 6.33%, alcanzando 0.0971. Este incremento sustancial refleja que la ganancia en precisión compensa la pequeña pérdida en exhaustividad.

Análisis de Consultas Ilustrativas

Consultas con Mayor Mejora

PLAIN-24: "Are Alkylphenol Endocrine Disruptors linked to allergies?"

Modelo	P@100	R@100	F1@100	Mejora
Baseline	0.10	0.2083	0.1351	---
Contextual	0.18	0.3750	0.2432	+80.0%

Table 17: PLAIN-24: Mejora sustancial con contextualización

PLAIN-82: "Are Canned Beans as Healthy as Home Cooked?"

Modelo	P@100	R@100	F1@100	Mejora
Baseline	0.01	0.0278	0.0147	---
Contextual	0.06	0.1667	0.0882	+500.0%

Table 18: PLAIN-82: Mejora extraordinaria (+500%)

Conclusiones del Ejercicio 7

1. **Mejora Sustancial en Precisión:** El incremento del 7.5% en P@100 es significativo en el contexto de recuperación de información biomédica
2. **Trade-off Precisión-Exhaustividad:** La ligera caída en exhaustividad (-0.92%) es despreciable frente a la ganancia en precisión
3. **Dependencia del Tipo de Consulta:** Las consultas que se benefician más son aquellas donde la información relevante está distribuida en el texto completo y requiere contexto adicional

Ejercicio 8: Sistema RAG con Chunks Agrupados

Metodología

Se implementó un sistema de Retrieval-Augmented Generation (RAG) que utiliza el buscador contextualizado del Ejercicio 7. El sistema agrupa chunks pertenecientes al mismo documento y los presenta precedidos una única vez por su título y abstract.

El proceso consta de tres etapas:

1. **Recuperación:** Se lanza la consulta contra el buscador contextualizado, obteniendo chunks con sus puntuaciones de relevancia
2. **Agrupación:** Los chunks se agrupan por documento, manteniendo el orden de relevancia global pero presentando todos los chunks de un mismo documento juntos
3. **Generación:** Se construye un prompt con la consulta y los chunks agrupados

Ejemplo de Ejecución

Consulta seleccionada: "What are the benefits of diet in juvenile rheumatoid arthritis?"

El sistema recuperó 12 chunks del documento MED-4084, todos relacionados con artritis reumatoide juvenil. Los chunks se agruparon y presentaron con su título y abstract común.

Chunks Recuperados:

- Ordenados por relevancia: MED-4084#29, #1, #2, #21, #25, #17, #8, #28, #15, #23, #0, #9
- Puntuaciones entre -0.3292 y -0.3661
- Prompt generado: 11,173 caracteres

Respuesta Generada por el LLM

El modelo identificó 5 pasajes relevantes: [MED-4084#0], [MED-4084#15], [MED-4084#28], [MED-4084#23], [MED-4084#9].

Respuesta narrativa:

La manipulación dietética y el ayuno han mostrado potenciales beneficios para individuos con artritis reumatoide juvenil (JRA). Según una encuesta de 742 pacientes reumáticos, un tercio reportaron agravación de síntomas tras la ingesta de alimentos. Un 26% había intentado varias dietas, reportando reducción en dolor, rigidez e hinchazón articular.

El ayuno también demostró beneficios potenciales. Ciertos alimentos como gluten y lácteos se han implicado en agravar síntomas. Los hallazgos sugieren que cambios dietéticos pueden ofrecer alivio para individuos con JRA, aunque las reacciones a alimentos son diversas.

Análisis del Sistema RAG

Fortalezas:

- Agrupación efectiva de chunks del mismo documento
- Selección correcta de pasajes relevantes
- Respuesta estructurada con citas apropiadas

Limitaciones:

- Falta de diversidad: todos los chunks de un único documento
- Longitud del prompt: 11,173 caracteres (puede exceder límites de contexto)
- Redundancia entre chunks

Ejercicio 9: Evaluación de Sistemas RAG mediante LLMs

Introducción

Objetivo: Evaluar la capacidad de los modelos de lenguaje grandes (LLMs) para actuar como jueces automáticos en la evaluación de sistemas RAG, analizando hasta qué punto pueden proporcionar evaluaciones fiables y consistentes en comparación con evaluadores humanos.

Metodología: Se seleccionaron 5 consultas médicas del corpus NFcorpus de forma aleatoria, ejecutando el sistema RAG para generar respuestas. Estas respuestas fueron evaluadas por GPT-5.2 Extended Thinking utilizando 4 criterios predefinidos: Grounding, Faithfulness, Completeness y Nuggets. Las evaluaciones del LLM se compararon con respuestas de referencia escritas por médicos profesionales.

Consultas Evaluadas

ID	Pregunta
PLAIN-16	Phytates in Beans: Anti-Nutrient or Anti-Cancer?

PLAIN-450	Are there benefits to drinking aloe vera juice?
PLAIN-2474	Do Flexitarians Live Longer?
PLAIN-2792	Are Cats or Dogs More Protective For Children's Health?
PLAIN-2885	Is It the Diet, the Exercise, or Both?

Table 19: Consultas evaluadas mediante LLM-as-Judge

Resultados Agregados por Criterio

Criterio	Media	Rango	Desviación
Grounding	2.80/5.0	2-4	Moderada
Faithfulness	2.60/5.0	2-3	Alta
Completeness	1.60/5.0	1-2	Baja
Nuggets	2.40/5.0	1-3	Moderada

Table 20: Puntuaciones de GPT-5.2 Extended Thinking (escala 1-5)

Observaciones clave:

- **Completeness** mostró la desviación estándar más baja, indicando alta consistencia
- **Grounding** obtuvo la puntuación promedio más alta (2.80/5), sugiriendo uso adecuado de chunks
- **Completeness** obtuvo la puntuación más baja (1.60/5), indicando respuestas frecuentemente incompletas
- **Nuggets** mostró variabilidad moderada en identificación de hechos clave

Ejemplo de Evaluación Detallada

Consulta: PLAIN-16 - "Phytates in Beans: Anti-Nutrient or Anti-Cancer?"

Evaluación GPT-5.2:

Criterio	Puntuación
Grounding	4/5
Faithfulness	3/5
Completeness	2/5
Nuggets	3/5

Table 21: Puntuaciones para PLAIN-16

Análisis de omisiones:

- Omite Polyp Prevention Trial
- Falta información cuantitativa específica (33% reducción de pólipos)
- No menciona mecanismos moleculares específicos (matrix metalloproteinasas)

Capacidad del LLM como Juez: Fortalezas Detectadas

Consistencia en la Evaluación:

GPT-5.2 Extended Thinking demostró alta consistencia especialmente en el criterio Completeness, aplicando los mismos estándares de forma uniforme.

Detección Precisa de Omisiones:

El LLM identificó correctamente aspectos faltantes:

- Datos cuantitativos específicos (porcentajes, tamaños de muestra)
- Estudios clínicos clave
- Mecanismos moleculares detallados

Coherencia Lógica entre Criterios:

Las puntuaciones mostraron coherencia: cuando Completeness era baja, Nuggets también tendía a ser bajo.

Debilidades y Limitaciones Identificadas

Expectativas Poco Realistas:

El principal problema fue que GPT-5.2 comparaba respuestas RAG automáticas con artículos médicos profesionales escritos por especialistas, que están editados profesionalmente e incluyen múltiples estudios integrados manualmente. Esta comparación es inherentemente injusta.

No Considera Limitaciones del Proceso RAG:

El evaluador LLM no distinguió entre:

- **Fallos de recuperación:** Chunks relevantes no fueron recuperados
- **Fallos de generación:** El modelo omitió información presente en los chunks
- **Limitaciones inherentes:** Información no disponible en la base de datos

Sesgo de Severidad:

GPT-5.2 Extended Thinking, como modelo de razonamiento profundo, fue excepcionalmente estricto. Una respuesta correcta pero incompleta recibió 1.60/5 en Completeness.

Principales Dificultades en Evaluación Automática RAG

Subjetividad de Criterios Cualitativos:

¿Qué significa "completo"? Depende del contexto (paciente vs médico vs estudiante).

Dependencia del Conocimiento del Dominio:

Sin expertise médico real, el LLM puede no detectar errores factuales sutiles o subvalorar simplificaciones apropiadas.

Evaluación de Recuperación vs Generación:

El sistema RAG tiene dos componentes. El LLM juez evalúa solo el output final, sin distinguir si un problema proviene de mala recuperación o mala generación.

Falta de Calibración Absoluta:

Sin calibración contra evaluadores humanos expertos, las puntuaciones son relativas y pueden no generalizarse.

Análisis Crítico: ¿Hasta Qué Punto un LLM Puede Actuar como Juez?

Casos de Uso Apropiados:

LLM-as-Judge es **viable y útil** para:

- ✓ Detección de fallos obvios
- ✓ Evaluación de grounding (fundamentación)
- ✓ Screening a gran escala
- ✓ Identificación de patrones
- ✓ Comparación relativa

Casos que Requieren Evaluación Humana:

LLM-as-Judge es **insuficiente** para:

- ✗ Evaluación de precisión médica
- ✗ Detección de sesgos sutiles
- ✗ Calibración de expectativas
- ✗ Evaluación de utilidad práctica
- ✗ Validación final de sistemas críticos

Recomendaciones para Mejorar la Evaluación Automática

- **Ensemble Judging:** Usar múltiples LLMs y promediar
- **Criterios más granulares:** Definir sub-criterios objetivos
- **Few-shot prompting:** Incluir ejemplos con puntuaciones de referencia
- **Validación humana periódica:** Calibrar contra expertos
- **Métricas complementarias:** Combinar con ROUGE, BERTScore
- **Separar componentes:** Evaluar recuperación y generación independientemente

Conclusiones del Ejercicio 9

Sobre el Sistema RAG Evaluado:

El sistema RAG demuestra capacidad funcional para recuperar chunks relevantes y generar respuestas coherentes. Sin embargo, enfrenta limitaciones en completitud comparado con contenido médico profesional, principalmente debido a chunks que no cubren todos los aspectos y modelo de generación que prioriza concisión.

Sobre LLM-as-Judge:

GPT-5.2 Extended Thinking como evaluador demuestra:

Fortalezas:

- Alta consistencia en criterios cuantitativos
- Capacidad para detectar omisiones específicas
- Comentarios explicativos útiles
- Evaluación rápida y escalable

Limitaciones:

- Expectativas desproporcionadas
- Incapacidad para contextualizar
- No distingue entre limitaciones del sistema vs errores
- Severidad excesiva

Viabilidad del Enfoque:

LLM-as-Judge es **parcialmente viable**:

- Útil como herramienta de screening
- Insuficiente como única métrica
- Complementario a evaluación humana
- Escalable para datasets grandes

Análisis Comparativo General

Patrones de Comportamiento

Cuándo BM25s es Mejor

Características: Consultas técnicas, vocabulario especializado sin ambigüedad, coincidencias léxicas directas frecuentes.

Ejemplos:

- PLAIN-2501 ("Dietary Factors Breast Cancer") - F1@100: BM25s 0.31 > Híbrida 0.19 > ChromaDB 0.26
- PLAIN-3373 ("Mercury Corn Syrup") - F1@100: BM25s 0.24 > Híbrida 0.22 > ChromaDB 0.21

Cuándo ChromaDB es Mejor

Características: Desajuste léxico-semántico, lenguaje coloquial vs terminología técnica, variantes y paráfrasis abundantes.

Ejemplos:

- PLAIN-3257 ("Is Stevia Good For You?") - F1@100: ChromaDB 0.2 > Híbrida 0.17 > BM25s 0.033
- PLAIN-2532 ("Flax Seeds Breast Cancer") - F1@100: ChromaDB 0.37 > Híbrida 0.293 > BM25s 0.24
- PLAIN-2759 ("Breast Cancer Alcohol Safety") - F1@100: ChromaDB 0.29 > Híbrida 0.2 > BM25s 0.2

Cuándo el Híbrido es Mejor

Características: Complementariedad entre modelos, vocabulario mixto, documentos con diferentes tipos de coincidencias relevantes.

Ejemplos:

- PLAIN-198 ("Pets Children Health") - F1@100: Híbrida 0.1 > BM25s 0.09 > ChromaDB 0.06

Análisis de Patrones de Fracaso

Fracasos Compartidos:

Tanto BM25s como ChromaDB fallan en:

- Consultas muy generales ("The Best Way to Prevent the Common Cold?")
- Consultas con múltiples conceptos solapados ("Viral Food Poisoning from Pesticides?")
- Consultas en lenguaje natural coloquial sin términos técnicos claros

Fracasos Específicos del Híbrido:

El híbrido falla cuando:

- Uno de los componentes tiene rendimiento muy pobre
- Los rankings de BM25s y ChromaDB son muy divergentes
- RRF premia la intersección, pero esa intersección no contiene relevantes

Conclusiones

Hallazgos Principales

1. **Equivalencia Agregada:** A nivel global, los tres modelos (BM25s: $F1@100=0.088$, ChromaDB: $F1@100=0.091$, Híbrida: $F1@100=0.089$) muestran rendimiento muy similar, con diferencias menores al 5%
2. **Diferencias Consulta-a-Consulta:** Las diferencias más significativas aparecen a nivel individual de consultas, donde un modelo puede ser superior en 300-500% al otro
3. **Especificidad de Consulta:**
 - Consultas técnicas → BM25s es óptimo
 - Consultas coloquiales → ChromaDB es óptimo
 - Consultas complementarias → Híbrida puede mejorar
4. **Límite de Calidad:** Los valores absolutos de rendimiento son bajos. Incluso el mejor resultado ($F1@100 \approx 0.09$) indica que solo el 9% de documentos en top-100 son relevantes. Todos los modelos tienen oportunidades significativas de mejora
5. **Desajuste Léxico-Semántico:** El principal factor limitante es el desajuste entre lenguaje natural de preguntas de usuarios y terminología especializada de artículos biomédicos. ChromaDB maneja mejor este desajuste, pero ni siquiera un modelo semántico lo resuelve completamente
6. **Mejoras Contextuales:** La contextualización de chunks en ChromaDB produce mejoras sustanciales (+7.5% en precisión, +6.33% en $F1@100$), demostrando el valor de proporcionar contexto adicional

Recomendaciones Prácticas

Para Consultas Técnicas: Usar BM25s o dar mayor peso a la componente léxica

Para Consultas Generales/Coloquiales: Usar ChromaDB o aumentar el peso semántico en búsquedas híbridas

Para Corpus Heterogéneos: Considerar ajustar dinámicamente los pesos de RRF según características detectadas de la consulta

Para Mejora General: Explorar técnicas adicionales como:

- Expansión de consultas con sinónimos controlados
- Re-ranking basado en relevancia semántica
- Modelos de lenguaje específicos del dominio biomédico
- Contextualización de fragmentos para mejorar evaluaciones semánticas
- Sistemas RAG para generación de respuestas fundamentadas

Limitaciones del Estudio

- Evaluación limitada a corpus biomédico (NFcorpus/PubMed)
 - Corpus de referencia predeterminado con posible sesgo en relevancia
 - RRF utiliza parámetro $k=60$ fijo; optimización de este parámetro no se realizó
 - No se exploró fusión adaptativa con pesos dinámicos
-

Referencias

[1] Chatbot Perplexity. (2025). Consultas sobre recuperación de información y análisis de búsqueda. Recuperado de [enlace](#)

[2] Transparencias del Curso. (2025-2026). Recuperación de Información. Recuperado de <https://docs.google.com/presentation/d/1BkiQDdbTrWgYvkoIc7o76xkQizILcYBZUF8rBxAgIXo/>

[3] Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333-389.

[4] Karpukhin, V., Oguz, B., Min, S., et al. (2020). Dense Passage Retrieval for Open-Domain Question Answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 6837-6851).

[5] Voorhees, E. M., & Harman, D. K. (2005). *TREC: Experiment and evaluation in information retrieval*. MIT Press.

[6] Chatbot Perplexity. (2025). Estilos del documento y mejoras en la presentación del mismo. Recuperado de [enlace](#)